Описание структуры проекта:

“Анализ поведения пользователей сайта "СберАвтоподписка" и разработка ML-модели для прогнозирования целевых действий”

Содержание

Основные файлы проекта:

1. Файл Jupyter Notebook (Lab)

`part_1_data_preprocessing_and_analysis.ipynb`

Подготовка основного датасета для моделирования и Анализ данных

- **Реализованы следующие этапы:**
  - **Подготовка данных:**
    - Загрузка исходных данных
    - Очистка от дубликатов и пропущенных значений
    - Типизация данных
  - **Создание новых признаков (Feature Engineering):**
    - Создание новых признаков из сырых данных:
      - Временные признаки из дат визитов
      - Категориальные признаки (utm-метки, device-устройства)
      - Географические признаки (geo)
  - **Анализ динамики, распределений и зависимостей:**
    - Источники трафика
    - Данные о визитах

        - Типы устройств
        - География пользователей
        - Взаимосвязи между признаками (матрицы корреляций)
    - **Визуализация:**
        - Динамика основных показателей
        - Гистограммы распределений
        - Heatmap и матрицы корреляций

2. Файл Jupyter Notebook (Lab)

`part_2_model_selection.ipynb`

Выбор и построение модели для предсказания целевого действия

- **Реализованы следующие этапы моделирования:**
    - Загрузка данных и создание основного датасета.
    - Создание Pipeline для предобработки данных.
    - Разделение данных на обучающую и тестовую выборки с применением undersampling для балансировки классов.
    - Обучение и сравнение моделей (`LogisticRegression`, `RandomForest`, `MLPClassifier`, `XGBoost`, `LightGBM`, `CatBoost`).
    - Подбор гиперпараметров для лучшей модели.
    - Подготовка финальной модели, обучение на всем датасете.
    - Сохранение и загрузка финальной модели.
    - Проверка загруженной модели, тестирование на выборке из основного датасета.
- **Результаты моделирования представлены в виде:**
    - Таблиц с метриками моделей (ROC-AUC, precision, recall, F1, accuracy).
    - Визуализация важности признаков и ROC-кривых.

3. Файлы Python:

- `main_api_sber.py`
    - **API-сервис (FastAPI)**
    - **Реализованы запросы:**
        - **GET:**
            - `status`
            - `version`
        - **POST:**

        - `predict`
- `pipeline_model_sber.py`
    - **Реализованы следующие этапы моделирования:**
        - Построение pipeline обработки исходных данных.
        - Обучение модели на тестовом датасете.
        - Кроссвалидация, оценка качества модели (`cross_val_score`).
        - Обучение модели на полном датасете.
        - Запись модели в папку `models`.
- `testing_on_examples.py`
    - Тестирование модели на json-файлах, примерах из папки `examples`.
    - В папке `examples` – 100 файлов (50 – с `target_action = 1` и 50 – с `target_action = 0`).
    - Результаты тестирования записываются в папку `test_results` в текстовый файл вида `test_results_YYYY-mm-dd_HH-MM-SS.txt`.
    - Время тестирования на 100 файлах порядка 30 секунд.

Директории проекта:

- **`data/`**
    - Содержит файлы с исходными данными:
        - `ga_sessions.pkl`
        - `ga_hits.pkl`
    - Ссылка на оригиналы файлов с данными (исходные данные)
- **`models/`**
    - В нее сохраняются обученные модели, pkl-файлы вида `model_prediction_sber*.pkl.`
    - Также здесь находится файл `locations.csv` с гео-координатами (широты и долготы).
    - Координаты получены с помощью пакета `geopy` и сохранены в этот файл.
    - Данные из файла `locations.csv` используются при создании новых признаков (`geo_latitude`, `geo_longitude`, `geo_distance_to_city_km`).
    - Есть отдельный режим получения координат налету, но он долго работает, порядка 40 минут.
- **`examples/`**
    - Содержит 100 примеров, json-файлов для тестирования работы моделей и API-сервиса.
    - Пример данных одного из файлов:

```
{
  "session_id": "2500012602493962943.1638337216.1638337216",
```

```
  "client_id": "582079543.1638337215",
  "visit_date": "2021-12-01",
  "visit_time": "08:40:16",
  "visit_number": 1,
  "utm_source": "ZpYIoDJMcFzVoPFsHGJL",
  "utm_medium": "banner",
  "utm_campaign": "LEoPHuyFvzoNfnzGgfcd",
  "utm_adcontent": "vCIpmpaGBnIQhyYNkXqp",
  "utm_keyword": "puhZPIYqKXeFPaUviSjo",
  "device_category": "mobile",
  "device_os": "Android",
  "device_brand": "Samsung",
  "device_model": null,
  "device_screen_resolution": "412x869",
  "device_browser": "Chrome",
  "geo_country": "Russia",
  "geo_city": "Bryansk",
  "target_event_action": 1
}
```


- `test_results/`
    - В нее сохраняются результаты тестирования модели (текстовые файлы) при запуске файла `testing_on_examples.py`.

Запуск API-сервиса:

PowerShell

1. **Запустить PowerShell из командной строки**
2. **Перейти в папку проекта PyCharm**
    - Путь на моем компьютере:

      `E:\Projects\Python\SkillBox\final_work`
3. **Активировать окружение проекта**

   ```
   .\.venv\Scripts\activate
   ```
4. **Запустить сервис "uvicorn"**

   ```
   uvicorn main_api_sber:app --reload
   ```

Postman

1. **Запустить Postman локально**
2. **Открыть Postman в браузере**
3. **Перейти в раздел работы с запросами**

4. **Выполнить запросы:**
    - **GET:**
        - `127.0.0.1:8000/status`
        - `127.0.0.1:8000/version`
    - **POST:**
        - `127.0.0.1:8000/predict`

Примеры для POST-запросов

(Здесь 3 примера. Больше примеров (100 файлов) – см. в папке `examples`.)

Формат запроса:

- **Body:** `raw` (JSON)

Пример 1:


```
{
  "session_id": "3432873700966186920.1625224106.1625224106",
  "client_id": "799278193.1625210792",
  "visit_date": "2021-07-02",
  "visit_time": "14:00:00",
  "visit_number": 3,
  "utm_source": "bByPQxmDaMXgpHeypKSM",
  "utm_medium": "referral",
  "utm_campaign": "LTuZkdKfxRGVceoWkVyg",
  "utm_adcontent": "JNHcPlZPxEMWDnRiyoBf",
  "utm_keyword": null,
  "device_category": "desktop",
  "device_os": null,
  "device_brand": "",
  "device_model": null,
  "device_screen_resolution": "1920x1080",
  "device_browser": "Chrome",
  "geo_country": "Russia",
  "geo_city": "Moscow",
  "target_event_action": 1
}
```

Пример 2:


```
{
  "session_id": "167161116639790856.1636992776.1636992776",
  "client_id": "38920230.1636992776",
  "visit_date": "2021-11-15",
  "visit_time": "19:12:56",
  "visit_number": 1,
  "utm_source": "BHcvLfOaCWvWTykYqHVe",
  "utm_medium": "cpc",
  "utm_campaign": null,
  "utm_adcontent": null,
  "utm_keyword": "lVHkqXlZapieOXCrCJWG",
  "device_category": "mobile",
  "device_os": "Android",
  "device_brand": "Xiaomi",
  "device_model": null,
  "device_screen_resolution": "393x873",
  "device_browser": "YaBrowser",
  "geo_country": "Russia",
  "geo_city": "Moscow",
  "target_event_action": 1
}
```

Пример 3:


```
{
  "session_id": "4087249450691937739.1626108893.1626108893",
  "client_id": "951636920.1625769419",
  "visit_date": "2021-07-12",
  "visit_time": "19:00:00",
  "visit_number": 9,
  "utm_source": "kjsLglQLzykiRbcDiGcD",
  "utm_medium": "cpc",
  "utm_campaign": null,
  "utm_adcontent": null,
  "utm_keyword": null,
  "device_category": "mobile",
  "device_os": null,
  "device_brand": "Apple",
  "device_model": null,
  "device_screen_resolution": "414x896",
  "device_browser": "Safari",
  "geo_country": "Russia",
  "geo_city": "Kazan",
  "target_event_action": 0
}
```

Скрины работающего API-сервиса:

- `GET-запрос /status`

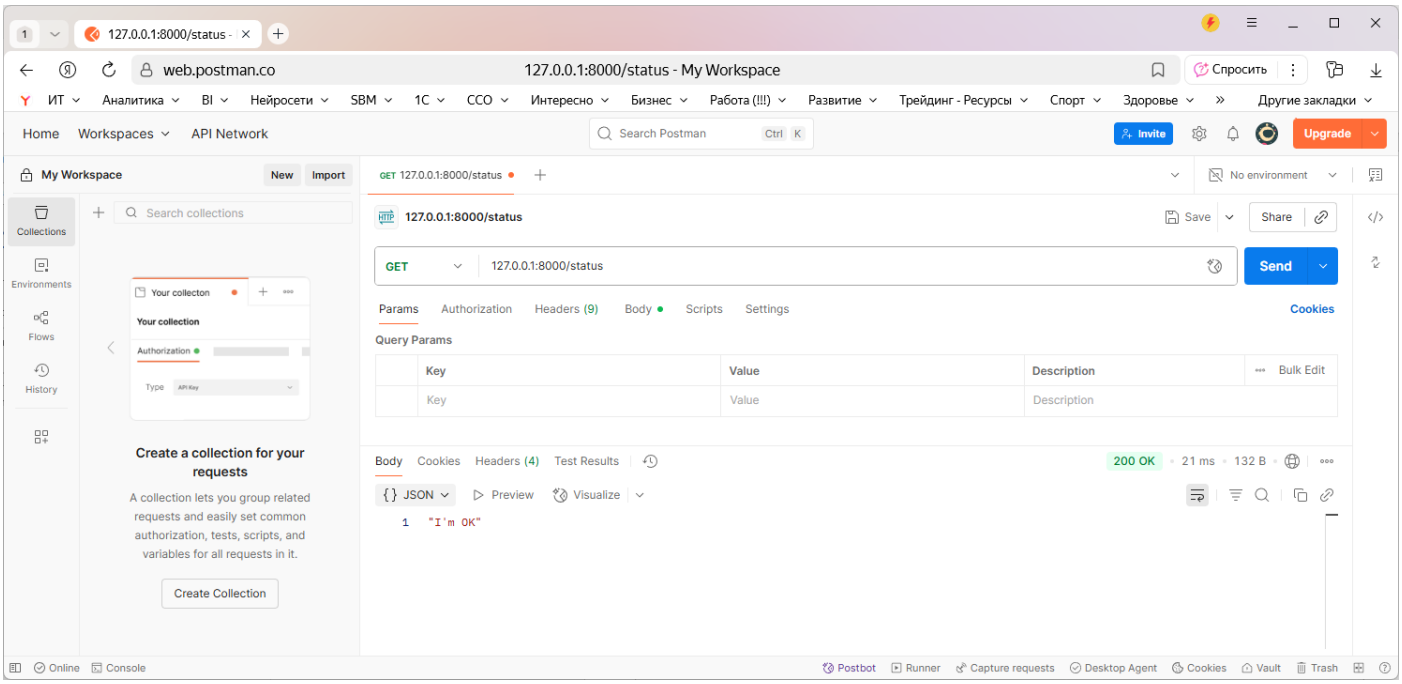

- `GET-запрос /version`

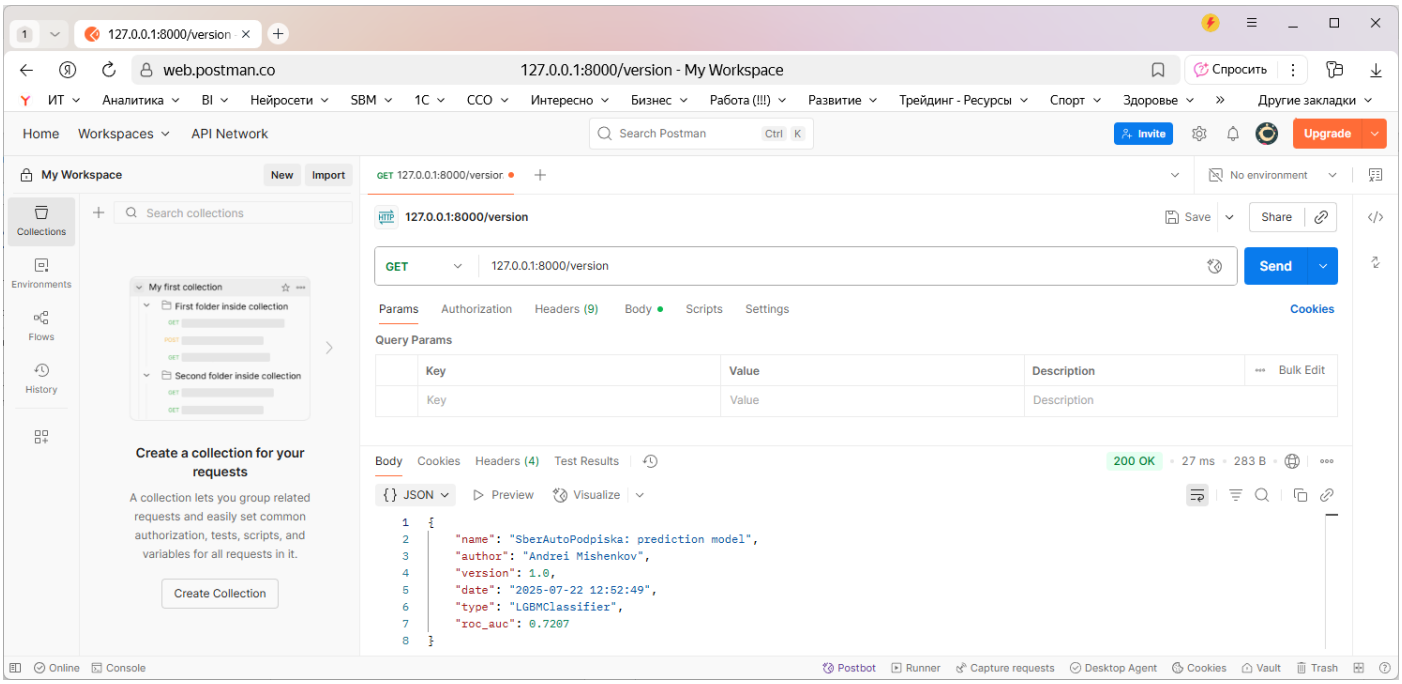

- `POST-запрос /predict (1-й пример)`

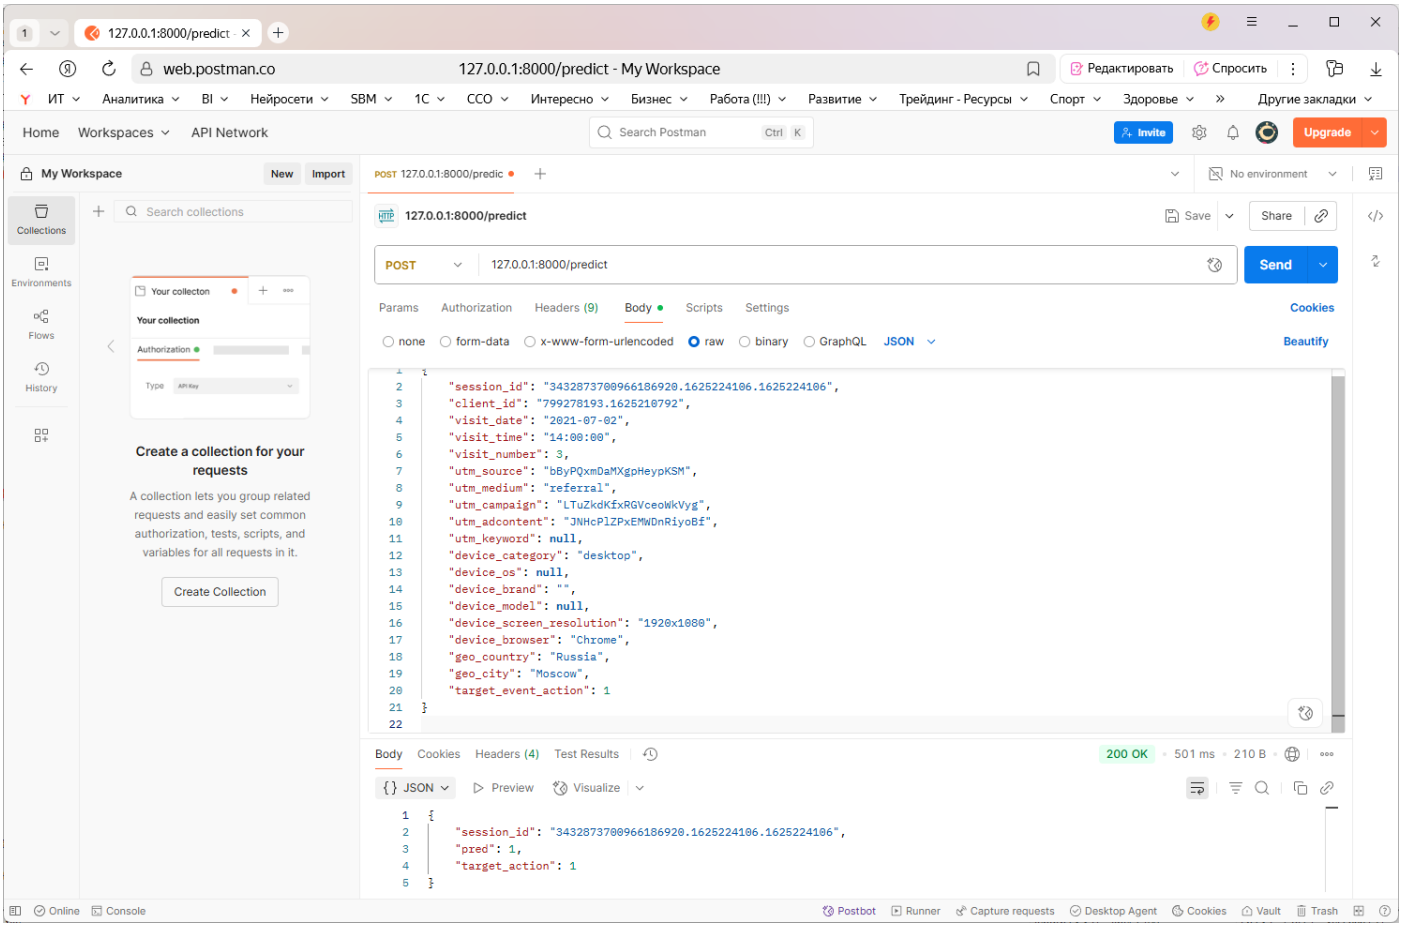

- POST-запрос /predict (2-й пример)

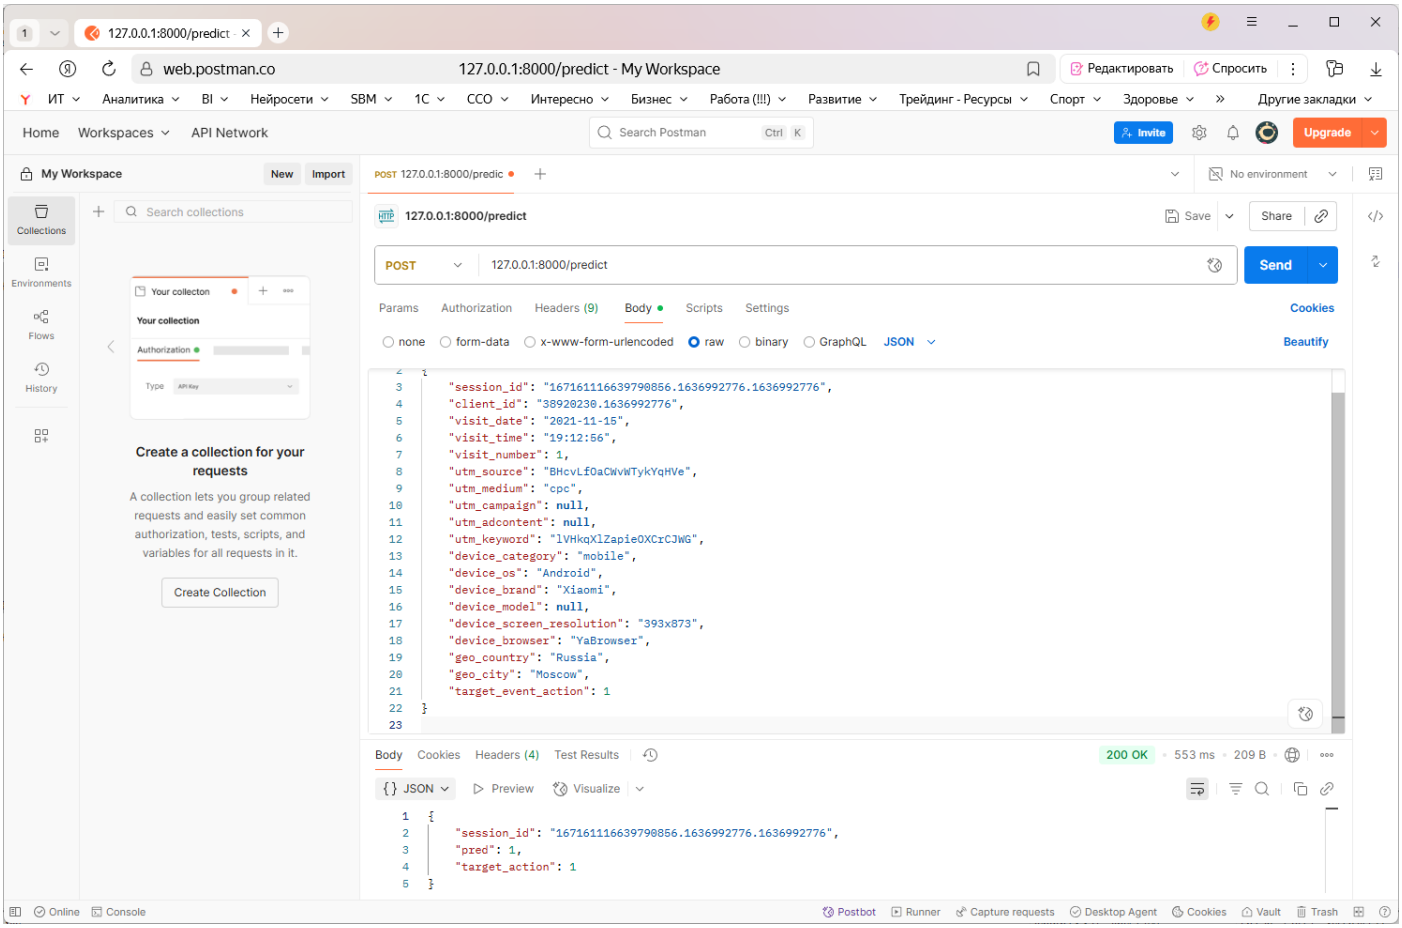

- `POST-запрос /predict (3-й пример)`